

Monitoreo de la deforestación en el Bosque Nacional Jamanxim (2000–2019) mediante segmentación de imágenes satelitales

David Camilo Muñoz García

RESUMEN

Este estudio analiza la evolución de la deforestación en el Bosque Nacional Jamanxim, en la Amazonía brasileña, entre 2000 y 2019, utilizando imágenes satelitales procesadas mediante técnicas avanzadas de segmentación. Se aplicaron métodos de preprocesamiento visual, detección de nubes, segmentación por color y umbral, y refinamientos morfológicos, con el fin de identificar y cuantificar áreas deforestadas en kilómetros cuadrados. Los resultados revelan una tendencia creciente, con un aumento lineal promedio de 52.15 km²/año. La metodología desarrollada demuestra ser una herramienta eficaz y replicable para el monitoreo ambiental, contribuyendo al seguimiento de políticas de conservación forestal.

I. INTRODUCCIÓN

La deforestación en la selva amazónica representa uno de los desafíos ambientales más apremiantes de nuestro tiempo, con consecuencias directas sobre la biodiversidad, el clima global y los ecosistemas locales [poner cita]. El monitoreo preciso y oportuno de este fenómeno es crucial para evaluar la efectividad de las políticas de conservación y para la toma de decisiones estratégicas. En este contexto, el procesamiento digital de imágenes ha emergido como una herramienta indispensable, permitiendo el análisis a gran escala de la cobertura terrestre a partir de datos satelitales.

Particularmente, las técnicas de segmentación juegan un papel fundamental al posibilitar la identificación y el aislamiento de áreas específicas de interés, como las zonas deforestadas, dentro de vastas extensiones geográficas capturadas por satélites. Estas técnicas transforman imágenes complejas en representaciones más simples y manejables, donde cada píxel se clasifica según su pertenencia a una categoría definida. Al aplicar métodos como la segmentación por umbral, se logra diferenciar entre zonas forestales y no forestales basándose en las variaciones de intensidad lumínica. Complementariamente, la segmentación basada en color aprovecha las diferencias cromáticas inherentes entre la vegetación intacta (verdes) y las áreas deforestadas (tonos marrones o rojizos) para una identificación más robusta.

El Bosque Nacional Jamanxim, ubicado en la Amazonía brasileña, es una región de crítica importancia ecológica. Su monitoreo a lo largo del tiempo es esencial para comprender la dinámica de la deforestación y el impacto de las estrategias de protección. Este estudio se enfoca en analizar la evolución de la deforestación en Jamanxim entre los años 2000 y 2019, utilizando imágenes satelitales de alta resolución provenientes del observatorio de la Tierra de la

NASA [poner cita]. A través de la aplicación de técnicas avanzadas de procesamiento y segmentación de imágenes, buscamos no solo cuantificar la extensión de las áreas deforestadas, sino también proporcionar una base para evaluar las tendencias temporales y la eficacia de los esfuerzos de conservación en esta valiosa región.

II. MATERIAL Y MÉTODOS

Para llevar a cabo el análisis de la deforestación en el Bosque Nacional Jamanxim, se empleó un enfoque metodológico riguroso basado en el procesamiento digital de imágenes. A continuación, se detallan los materiales utilizados y las técnicas aplicadas.

A. Materiales

El desarrollo y la ejecución de este análisis se realizaron utilizando el lenguaje de programación Python, complementado con un conjunto de librerías especializadas en procesamiento de imágenes y manipulación de datos:

- OpenCV: Fundamental para operaciones de lectura, escritura y manipulación de imágenes, así como para la aplicación de filtros y transformaciones.
- scikit-image: Utilizada para algoritmos avanzados de procesamiento de imágenes, incluyendo transformaciones de espacios de color, operaciones morfológicas y algoritmos de segmentación.
- NumPy: Esencial para el manejo eficiente de arrays multidimensionales, permitiendo operaciones numéricas de alto rendimiento sobre los datos de imagen.
- Matplotlib: Empleada para la visualización de imágenes y la generación de gráficos de los resultados.
- PIL: Utilizada para la extracción de los fotogramas del archivo GIF.
- SciPy: Para funciones de procesamiento de imágenes n-dimensionales.

* Autor de correspondencia:

Correo electrónico: davidcamilo0710@gmail.com (David Camilo Muñoz García)

Los datos de entrada consistieron en veinte imágenes satelitales correspondientes a los años 2000 a 2019, obtenidas de un archivo GIF (su resolución original es 720 px x 800 px) proporcionado por el NASA Earth Observatory [poner cita]. Estas imágenes, representadas en color natural, muestran la evolución de la cobertura forestal en el Bosque Nacional Jamanxim. La calibración espacial de las imágenes indica que 20 kilómetros equivalen aproximadamente a 51 píxeles, una relación crucial para la conversión de áreas de píxeles a kilómetros cuadrados.

Puede encontrar el código en el repositorio [poner cita] https://github.com/davidcamilo0710/deforest_amazonia.git.

B. Métodos

El proceso de análisis de la deforestación se estructuró en un pipeline modular, que incluyó varias etapas de preprocesamiento, segmentación y análisis cuantitativo:

1. Extracción y Preprocesamiento de Imágenes



Figura 1: Recorte y rotación del GIF.

Inicialmente, el archivo GIF se recortó y se giró como se observa en la Figura 1. Las imágenes individuales fueron extraídas del archivo GIF y posteriormente, cada imagen satelital fue sometida a un riguroso proceso de preprocesamiento para mejorar su calidad visual y realzar las características de interés:

Ajuste de Intensidad y Mejora de Contraste: Para optimizar la visibilidad de las áreas deforestadas, se aplicaron las siguientes técnicas:

- **Ecualización del Histograma:** Esta técnica distribuye los valores de intensidad de los píxeles de manera más uniforme en todo el rango dinámico de la imagen, aumentando el contraste global y haciendo más evidentes las diferencias entre distintas regiones.
- **Ecualización Adaptativa del Histograma con Contraste Limitado (CLAHE):** A diferencia de la ecualización global, CLAHE opera localmente, aplicando la ecualización en pequeñas regiones de la imagen. Esto evita la sobre-

amplificación del ruido en áreas homogéneas y mejora el contraste de manera más efectiva en zonas con características sutiles.

- **Filtro Bilateral:** Se utilizó un filtro bilateral para reducir el ruido en la imagen mientras se preservaban los bordes importantes. Este filtro es no lineal y considera tanto la proximidad espacial como la similitud de intensidad para el suavizado, siendo ideal para mantener la definición de los límites entre áreas forestales y deforestadas.

Imagen Original



Ecuallización de Histograma



CLAHE (Contraste Adaptativo)



Filtro Bilateral



Figura 2: Comparación de las mejoras de contraste aplicadas a una imagen satelital del año 2014. Se observa la imagen original, seguida de la ecualización de histograma, CLAHE y el resultado final del filtro bilateral.

2. Detección y Remoción de Nubes

Antes de la segmentación, fue fundamental identificar y enmascarar las áreas cubiertas por nubes, ya que estas pueden distorsionar los resultados de deforestación. Se implementó un algoritmo avanzado de detección de nubes que combina información

de múltiples espacios de color:

- Se convirtieron las imágenes a los espacios de color **HSV** (Matiz, Saturación, Valor) y **LAB** (Luminosidad, a^* , b^*).
- Se utilizaron criterios basados en los canales H, S, V de HSV (valores altos de V y bajos de S para nubes brillantes) y los canales L, a^* , b^* de LAB (altos valores de L y a^* , b^* cercanos a cero para blancos y grises).
- Se incorporó un análisis de gradiente sobre la imagen en escala de grises, ya que las nubes suelen presentar una textura más uniforme y, por ende, gradientes de intensidad bajos en comparación con las superficies terrestres.
- Finalmente, se combinaron estas detecciones con operadores booleanos (OR) para generar una máscara de nubes robusta.

3. Segmentación de Áreas Deforestadas

La identificación de las zonas deforestadas se realizó mediante una combinación de técnicas de segmentación por color y por umbral, seguida de un refinamiento morfológico:

- **Segmentación por Color:**
 - Espacio LAB: Se aprovechó la representación del color en el espacio LAB, donde el canal a^* (verde a rojo) es sensible a la presencia de vegetación y el canal b^* (azul a amarillo) ayuda a identificar suelos expuestos. Una combinación ponderada de estos canales, junto con el canal L* (luminosidad), permitió resaltar las áreas con características espectrales de deforestación.
 - Espacio HSV: Se definieron rangos específicos de matiz (H), saturación (S) y valor (V) para capturar diferentes tipos de áreas deforestadas, incluyendo suelos desnudos (amarillos, naranjas) y vegetación degradada o perturbada (verdes claros).
- **Segmentación por Umbral:** Tras la segmentación por color, se aplicó un umbral adaptativo (basado en el método de Otsu pero ajustado) para convertir las imágenes de color a una representación binaria, donde los píxeles deforestados se distinguen claramente.

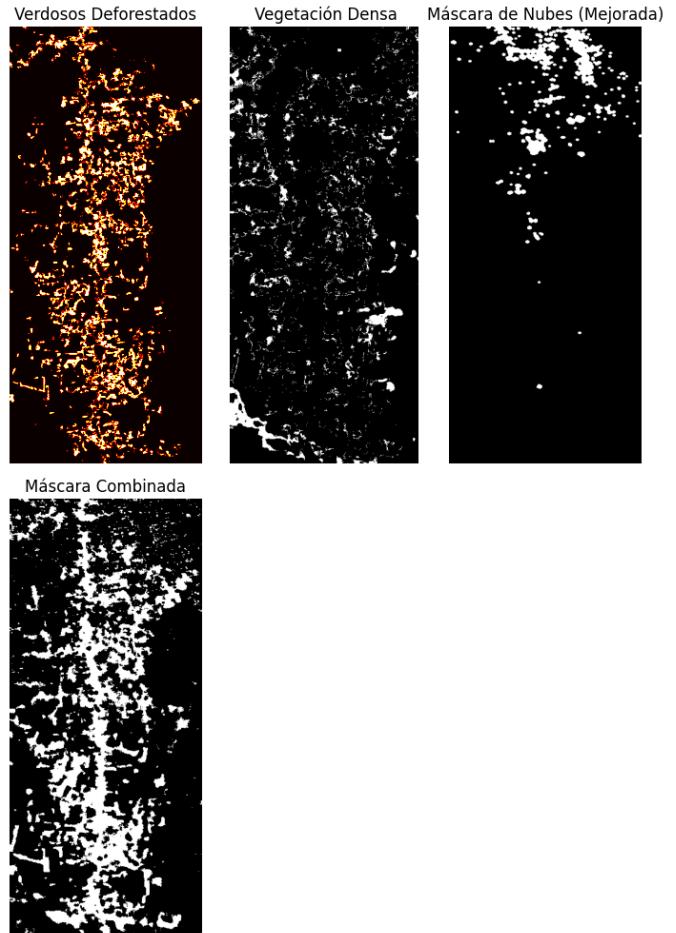
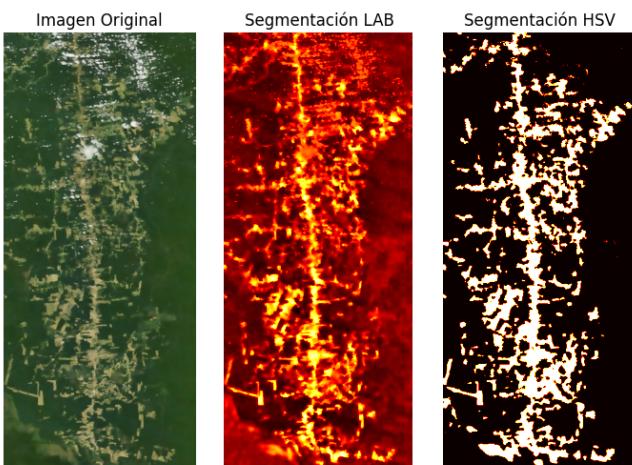


Figura 3: Visualización de las máscaras de segmentación por color y otros componentes clave del proceso para el año 2014.

4. Detección de Estructuras Lineales y Refinamiento Morfológico

Para mejorar la precisión de la segmentación e incluir elementos como caminos y carreteras que a menudo preceden o acompañan la deforestación, se implementaron técnicas para detectar estructuras lineales:

- Transformada de Hough Probabilística (HoughLinesP): Se aplicó esta transformada sobre los bordes de la imagen para identificar segmentos de líneas rectas, correspondientes a carreteras o senderos.
- Morfología Direccional y Esqueletización: Se utilizaron kernels morfológicos específicos (horizontales, verticales, diagonales) para realzar y extraer las estructuras lineales. Posteriormente, la esqueletización se aplicó para reducir estas estructuras a su representación más delgada, preservando su conectividad.
- La máscara final de deforestación se refinó utilizando operadores morfológicos como la apertura (para eliminar pequeños ruidos y artefactos) y el cierre (para conectar regiones cercanas y cerrar pequeñas brechas), empleando kernels elípticos que se adaptan mejor a las formas irregulares de las áreas deforestadas.

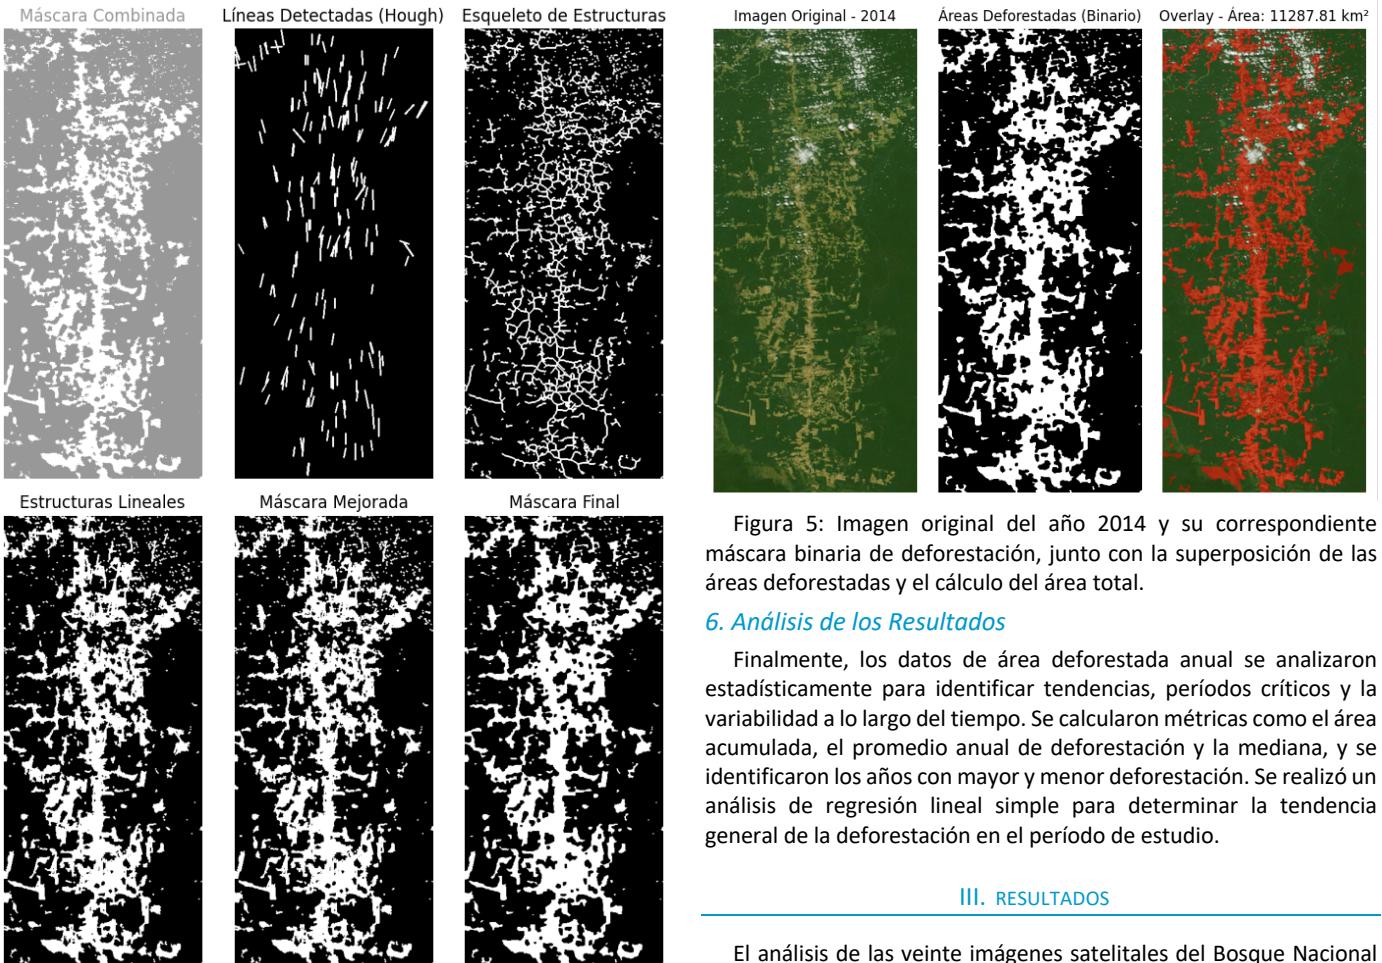


Figura 4: Pasos intermedios del refinamiento de la máscara de deforestación para el año 2014, incluyendo la detección de estructuras lineales y la máscara mejorada.

5. Cálculo del Área Deforestada

Una vez obtenidas las imágenes binarias resultantes de la segmentación, donde los píxeles blancos representan áreas deforestadas y los negros el resto, se procedió al cálculo del área afectada en kilómetros cuadrados (km^2). Esto se logró contando el número total de píxeles blancos en la máscara final y aplicando la relación de escala previamente definida:

$$\text{Área deforestada } (\text{km}^2) = \text{Número de píxeles deforestados} \times \left(\frac{20 \text{ km}}{51 \text{ píxeles}} \right)^2$$

Este cálculo se realizó para cada una de las veinte imágenes, obteniendo una serie temporal de la extensión de la deforestación.

Figura 5: Imagen original del año 2014 y su correspondiente máscara binaria de deforestación, junto con la superposición de las áreas deforestadas y el cálculo del área total.

6. Análisis de los Resultados

Finalmente, los datos de área deforestada anual se analizaron estadísticamente para identificar tendencias, períodos críticos y la variabilidad a lo largo del tiempo. Se calcularon métricas como el área acumulada, el promedio anual de deforestación y la mediana, y se identificaron los años con mayor y menor deforestación. Se realizó un análisis de regresión lineal simple para determinar la tendencia general de la deforestación en el período de estudio.

III. RESULTADOS

El análisis de las veinte imágenes satelitales del Bosque Nacional Jamanxim, que abarcan el período 2000-2019, permitió cuantificar la extensión de la deforestación y observar su evolución temporal. La aplicación secuencial de las técnicas de procesamiento y segmentación de imágenes fue fundamental para lograr una identificación y aislamiento precisos de las áreas deforestadas.

A. Impacto Visual de las Técnicas de Segmentación

El proceso de preprocesamiento, que incluyó la ecualización del histograma, la Ecualización Adaptativa del Histograma con Contraste Limitado (CLAHE) y el filtro bilateral, demostró un impacto significativo en la mejora de la calidad visual de las imágenes satelitales. Como se ilustra en la Figura 2 para una imagen del año 2014, estas transformaciones realizaron los detalles de la superficie, haciendo que las zonas de transición entre bosque denso y áreas deforestadas fueran más discernibles y que los tonos asociados a la degradación forestal, como los marrones y rojizos, se distinguieran con mayor claridad del entorno circundante. Esto fue esencial para preparar las imágenes para una segmentación efectiva.

La combinación de la detección de nubes mejorada con las técnicas de segmentación por color en los espacios LAB y HSV, seguida de una umbralización adaptativa, culminó en la generación de máscaras binarias altamente representativas de las áreas deforestadas. La Figura 3 muestra este progreso: desde las representaciones de color que resaltan los contrastes espectrales (LAB y HSV), hasta la efectiva eliminación de las interferencias nubosas y la consolidación de la máscara binaria final. Esta secuencia de procesamiento permitió discriminar eficazmente entre la vegetación sana, las zonas de deforestación y las áreas cubiertas por nubes, resultando en una segmentación visualmente coherente.

Finalmente, el refinamiento mediante operadores morfológicos y la detección de estructuras lineales (carreteras, senderos) mejoraron la calidad de la segmentación. Esto se tradujo en máscaras binarias más limpias, donde pequeños artefactos fueron eliminados y regiones deforestadas fragmentadas se conectaron lógicamente. La superposición de la máscara final sobre la imagen original, como se observa en la Figura 5, valida la capacidad del algoritmo para delinear de forma precisa las zonas deforestadas, lo cual es fundamental para una cuantificación fiable del área. Contemplemos el resultado para los años 2000 y 2019, es decir el inicio y el fin.

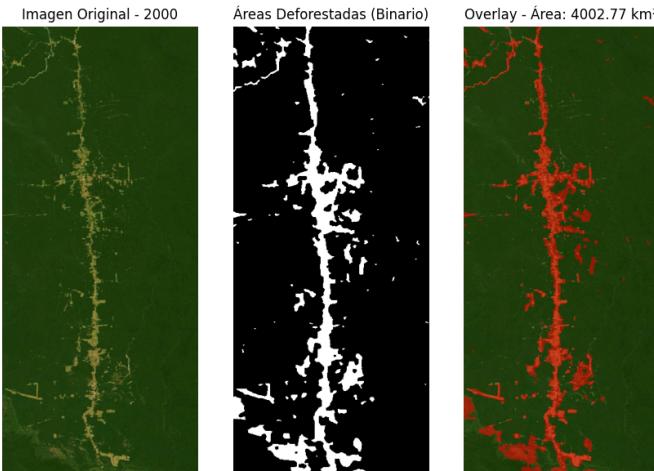


Figura 6: Imagen original del año 2000 y su correspondiente máscara binaria de deforestación, junto con la superposición de las áreas deforestadas y el cálculo del área total.

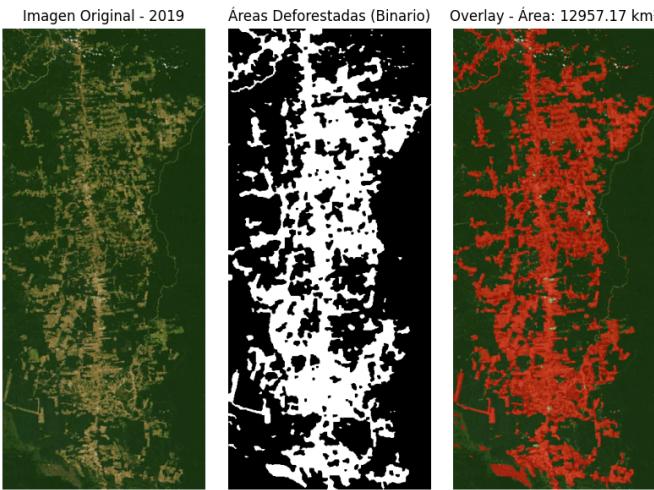


Figura 7: Imagen original del año 2019 y su correspondiente máscara binaria de deforestación, junto con la superposición de las áreas deforestadas y el cálculo del área total.

B. Cuantificación y Análisis Temporal de la Deforestación

Los cálculos del área deforestada por año, realizados sobre las máscaras binarias generadas, revelaron la siguiente evolución cuantitativa en el Bosque Nacional Jamanxim:

Año	Área Deforestada (km ²)
2000	4002
2001	4805
2002	3631
2003	3082
2004	5673

2005	5096
2006	6770
2007	9250
2008	9036
2009	8160
2010	8119
2011	11022
2012	10112
2013	9417
2014	11287
2015	11206
2016	11374
2017	12755
2018	12968
2019	12957

Tabla 1: Área deforestada anual en el Bosque Nacional Jamanxim (2000-2019).

La serie temporal (Tabla 1) indica una tendencia general de incremento en el área acumulada de deforestación a lo largo del período estudiado. El área total acumulada de deforestación al final de 2019 alcanzó los 12957.17 km², lo que representa un aumento significativo desde los 4002.77 km² registrados en el año 2000. El promedio anual de deforestación fue de 647.86 km², con una notable desviación estándar de 1486.61 km², señalando una alta variabilidad en la tasa de deforestación de un año a otro.

La Figura 8 ilustra claramente esta tendencia acumulada, mostrando un crecimiento constante a lo largo del tiempo. Aunque la Figura 9 (Deforestación Anual) revela fluctuaciones, incluyendo años donde el área deforestada calculada fue menor que la del año anterior (indicado por valores negativos o muy bajos en la variación anual, como en 2002, 2003, 2005, 2008, 2009, 2010, 2012, 2013, 2015 y 2019), la tendencia lineal general, mostrada en la Figura 10, indica un aumento promedio de 52.15 km²/año en el área deforestada.

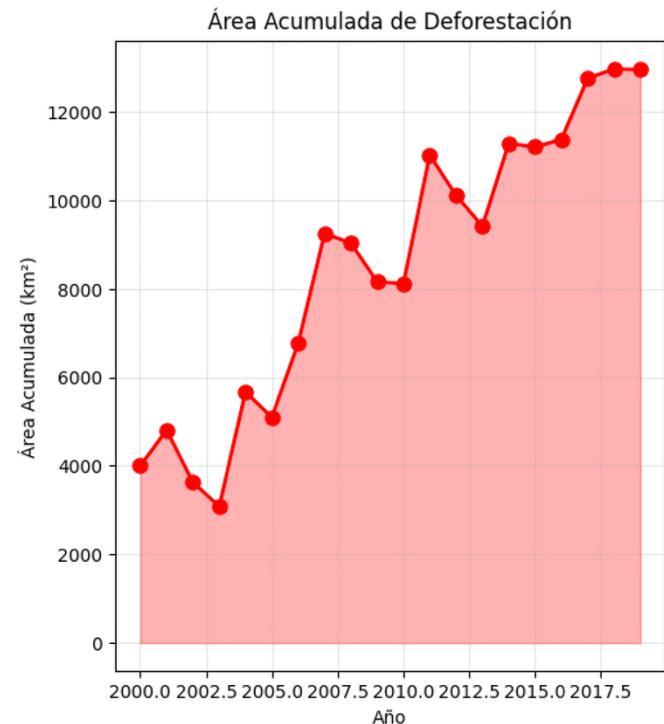


Figura 8: Gráfico de Área Acumulada de Deforestación en el Bosque Nacional Jamanxim (2000-2019).

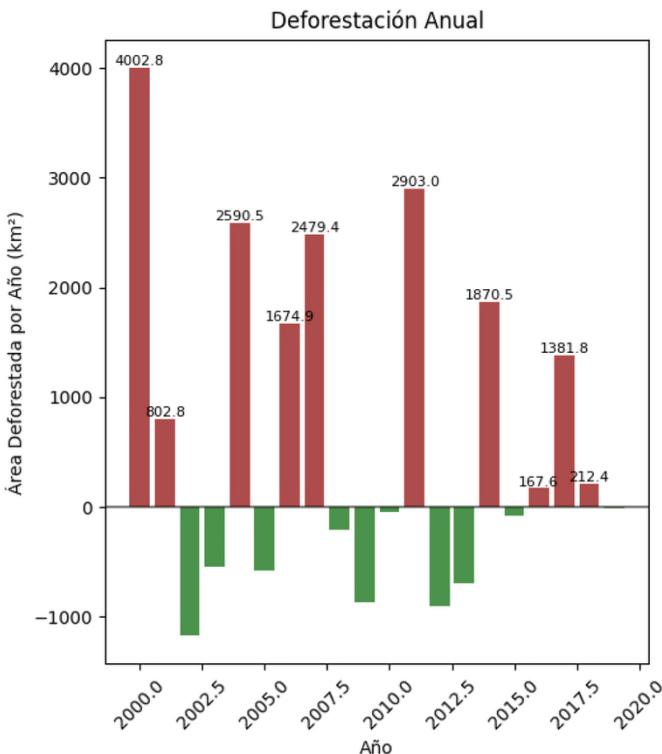


Figura 9: Gráfico de Deforestación Anual en el Bosque Nacional Jamanxim (2000-2019).

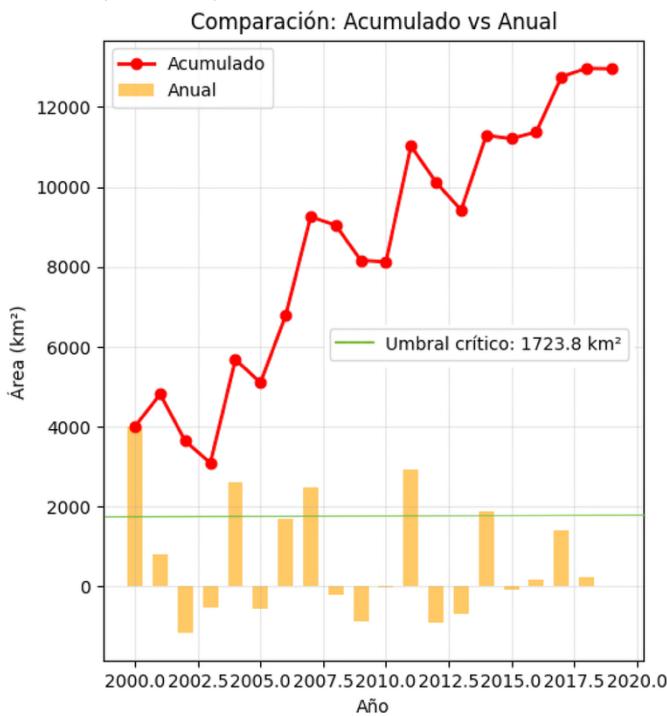


Figura 10: Comparación Acumulado vs. Anual.

Los años con mayor deforestación acumulada fueron 2017 (12755.86 km^2), 2018 (12968.24 km^2) y 2019 (12957.17 km^2), lo que sugiere una intensificación de la actividad en los últimos años del período analizado. Se identificaron también períodos críticos de deforestación (superiores a $1723.8 \text{ km}^2/\text{año}$, que marcan desviaciones significativas de la media), los cuales incluyen los años 2000, 2004, 2007, 2011 y 2014. La deforestación promedio durante estos picos fue de 2769.24 km^2 , indicando momentos de aceleración

en la pérdida de cobertura forestal que podrían estar asociados con factores externos específicos.

IV. CONCLUSIONES GENERALES

Este estudio ha demostrado la efectividad y el valor de las técnicas avanzadas de procesamiento y segmentación de imágenes para el análisis de la deforestación en el Bosque Nacional Jamanxim durante el período 2000-2019. Los hallazgos cuantitativos revelan un incremento persistente en el área deforestada acumulada, evidenciado por una tendencia lineal positiva de $52.15 \text{ km}^2/\text{año}$, lo que subraya la continua presión sobre este ecosistema vital. La capacidad de identificar y cuantificar las áreas deforestadas de forma automatizada es crucial para el monitoreo ambiental y la evaluación de la eficacia de las políticas de conservación [poner cita].

La combinación de las técnicas de segmentación por umbral (adaptativa) y, en particular, la segmentación basada en color en los espacios LAB y HSV, resultó ser la más eficaz para la identificación de las áreas deforestadas. La segmentación en LAB mostró una excelente capacidad para diferenciar suelos expuestos y vegetación degradada por sus propiedades de color y luminosidad, mientras que HSV complementó esta detección al capturar matices específicos que no son evidentes en RGB. Visualmente, las máscaras generadas exhiben una gran precisión en la delimitación de las zonas deforestadas, logrando excluir eficazmente la vegetación sana y las áreas nubladas, lo que resalta la robustez del algoritmo desarrollado. El preprocessamiento con CLAHE y el filtro bilateral fue un paso crítico que mejoró la visibilidad y el contraste, permitiendo que las técnicas de segmentación operaran con mayor eficiencia.

A pesar de la alta coherencia visual y la utilidad de los resultados cuantitativos, es fundamental reconocer ciertas limitaciones de este análisis. La principal radica en la ausencia de un ground truth o datos de validación de campo que permitan cuantificar la exactitud del área deforestada en kilómetros cuadrados con una referencia externa. Si bien las máscaras se ven muy bien y la segmentación parece exitosa, no se puede determinar la desviación numérica respecto a una verdad absoluta.

Otra limitación importante es la influencia de la variabilidad en las condiciones de iluminación y la calidad de las imágenes satelitales a lo largo de los años (la resolución del GIF original es $720 \text{ px} \times 800 \text{ px}$). Si bien el algoritmo logra una buena detección general, las sutiles variaciones en la atmósfera o la captura de la imagen entre un año y otro pueden generar pequeñas inconsistencias, manifestadas en los ocasionales valores negativos o muy bajos en la deforestación anual entre años consecutivos. Aunque estos casos son mínimos y no alteran la tendencia general al alza de la deforestación acumulada, indican un área de mejora para futuros trabajos. La optimización del algoritmo para lograr una calibración aún más adaptativa a las diferentes condiciones de las imágenes podría reducir estas pequeñas discrepancias y mejorar la consistencia interanual de la detección.

A pesar de estas consideraciones, la metodología implementada proporciona una herramienta poderosa y replicable para el monitoreo temporal de la deforestación. La identificación de períodos críticos y la cuantificación precisa del área deforestada ofrecen información valiosa para los tomadores de decisiones y para la evaluación de la efectividad de las iniciativas de conservación en el Bosque Nacional Jamanxim.

DECLARACIÓN DE CONTRIBUCIÓN DE AUTORÍA

David Camilo Muñoz García: conceptualización, metodología, análisis formal, desarrollo del software, validación, visualización, redacción – borrador original, redacción – revisión y edición, administración del proyecto.

BIBLIOGRAFÍA

- [1] A. B. Corrêa and J. Seipp, “*Consolidating LAMA with best-first width search,*” arXiv preprint arXiv:2404.17648, Apr. 2024. [Online]. Available: <https://arxiv.org/abs/2404.17648>.
- [2] potassco, “*pddl-instances: PDDL benchmark instances covering the International Planning Competitions,*” GitHub, 2020. [Online]. Available: <https://github.com/potassco/pddl-instances>. Accessed: Jun. 16, 2025.
- [3] *Fast Downward Planning System*, “*Fast Downward,*” [Online]. Available: <https://www.fast-downward.org/latest/>. Accessed: Jun. 16, 2025.
- [4] M. Katz, S. Sohrabi, H. Samulowitz, and S. Sievers, “*Delfi: Online planner selection for cost-optimal planning,*” in *Planner Abstracts of the Ninth International Planning Competition (IPC-9)*, 2018, pp. 55–62. [Online]. Available: <https://ai.dmi.unibas.ch/papers/katz-et-al-ipc2018.pdf>.
- [5] S. Richter and M. Westphal, “*The LAMA planner: Guiding cost-based anytime planning with landmarks,*” *Journal of Artificial Intelligence Research*, vol. 39, pp. 127–177, 2010. [Online]. Available: <https://www.jair.org/index.php/jair/article/view/10667>.
- [6] University of Lincoln Advanced Robotics (LCAS), “*Fast Downward Planning on the Web,*” [Online]. Available: <https://lcas.lincoln.ac.uk/fast-downward/>. Accessed: Jun. 16, 2025.

David Camilo Muñoz Garcia



Ingeniero en Electrónica y Telecomunicaciones por la Universidad del Cauca (Colombia, 2022) y estudiante de Maestría en Inteligencia Artificial en la Universidad Internacional de La Rioja (España). Cuenta con experiencia en análisis de datos, inteligencia artificial y automatización de procesos.

Ha liderado proyectos de visualización, modelado predictivo y arquitectura de datos en diversos sectores. Sus intereses se centran en la aplicación práctica de la IA para la toma de decisiones y la eficiencia organizacional.